

Detekcija kvara asinhronne mašine

Student: Nedeljko Ćuso RA175/2023

1.Uvod

Asinhroni (indukcioni) motori predstavljaju jedan od najrasprostranjenijih tipova elektromotora u industriji, zbog svoje robusnosti, jednostavnosti konstrukcije i niske cijene održavanja. Međutim, u toku eksploatacije motori mogu biti izloženi različitim vrstama kvarova, od kojih je jedan od najučestalijih gubitak jedne faze napajanja (open-phase fault), koji nastaje tokom prekida provodnika, otkaza osigurača ili kontaktora na jednoj od tri napojne faze.

Pravovremena detekcija ovakvog kvara je od velikog značaja jer produžen rad motora u stanju gubitka faze dovodi do prekomernog zagrijavanja, vibracija i ubrzanog habanja namotaja, što može rezultovati trajnim oštećenjem motora. Metode mašinskog učenja mogu se koristiti kao pomoćni alat za automatsku analizu signala motora i rano otkrivanje ovakvih stanja.

Cilj ovog projekta je razvoj modela mašinskog učenja za binarnu klasifikaciju režima rada asinhronog motora na osnovu fizičkih veličina dobijenih iz Simulink simulacije motora. Model klasifikuje rad motora u jednu od dvije klase: zdrav rad (Klasa 0) ili gubitak jedne faze (Klasa 1).

Problem pripada nadgledanom učenju (Supervised Learning), jer je za svaki uzorak poznata ciljna promjenljiva Klasa. Pošto postoje dve moguće vrednosti izlazne promjenljive, zadatak je binarna klasifikacija. U radu su, u skladu sa specifikacijom predmeta, korišćena dva algoritma obrađena na predavanjima: logistička regresija i k-najbližih susjeda (k-NN), uz odgovarajuću evaluaciju, podešavanje hiperparametara, odabir najznačajnijih atributa i jednostavan deployment modela.

2.Opis problema i dataset

Dataset je generisan simulacijom napona matematičkog modela asinhronne mašine u Simulinku (model MModel_AM), koji je u petlji pokretan za niz različitih radnih tačaka opterećenja, posebno za zdrav rad i posebno za stanje gubitka jedne faze. Ulaz u model čine fizičke veličine motora izmjerene u stacionarnom stanju, dok je izlaz modela klasa režima rada motora.

Stavka	Vrednost
Broj uzoraka	1400
Broj kolona u originalnom datasetu	10
Uklonjena kolona	T (momenat) — sadržala isključivo NaN vrijednosti
Broj ulaznih atributa nakon pripreme	8
Ciljna promjenljiva	Klasa

Ulazni atributi modela su sledeće fizičke veličine motora:


- U_s - efektivni napon statora [V]
- I_s - vrijednost struje statora [A]
- s - klizanje motora
- Vib - nivo vibracija
- THD - Total Harmonic Distortion (procenat harmonijskog izobličenja)
- P_f - faktor snage ($\cos \varphi$)
- Brzina - mehanička brzina rotora [rpm]
- Temp - temperatura motora

Klasa Klasa je kodirana na sledeći način:

Originalna oznaka	Kodirana vrijednost	Značenje
Zdrav rad	0	Motor radi ispravno, sve tri faze napajanja prisutne
Gubitak faze	1	Jedna od tri faze napajanja je prekinuta (open-phase fault)

Raspodela klasa u datasetu je sledeća:

Klasa	Broj uzoraka
Zdrav rad (0)	700
Gubitak faze (1)	700



Slika: Raspodjela uzoraka zdravog rada i gubitka faze

Dataset je savršeno balansiran (50% / 50%), što pojednostavljuje proces treniranja jer nije bilo potrebno primjenjivati tehnike za balansiranje klasa niti pridavati posebnu težinu klasama prilikom optimizacije modela.

3.Preprocesiranje i sprječavanje dataleakage-a

Priprema podataka obuhvatila je učitavanje originalnog CSV fajla dobijenog iz MATLAB/Simulink simulacije, provjeru kvaliteta podataka, uklanjanje neupotrebljive kolone i standardizaciju ulaznih atributa.

Provera	Rezultat
Nedostajuće vrijednosti (ukupno)	1400 (isključivo u koloni T)
Duplikati	0
Enkodiranje ciljne promjenljive	Nije bilo potrebno - Klasa je već numerička (0/1)
Vještačko generisanje podataka	Nije korišćeno

Kolona T (momenat motora) sadržala je isključivo NaN vrijednosti zbog neispravno povezanog Goto/Scope bloka u Simulink šemi prilikom logovanja signala momenat_sim. Pošto ne postoji nijedna validna vrijednost u toj koloni, atribut je u potpunosti uklonjen, jer se prazna kolona ne može imputirati niti koristiti u modelu, a preostalih osam atributa fizički potpuno korektno opisuje stanje motora.

Posebna pažnja posvećena je sprječavanju data leakage-a:

- Podjela na trening i test skup izvršena je prije bilo kakvog skaliranja podataka, u odnosu 80:20, uz stratifikaciju (stratify=y) kako bi se sačuvao ravnomjeren odnos klasa u oba skupa.
- Standardizacija (StandardScaler) je fitovana isključivo nad trening skupom (fit_transform), dok je nad test skupom primjenjena samo transformacija (transform) sa već naučenim parametrima.
- Odabir najznačajnijih atributa izvršen je takođe isključivo na trening skupu, kako test skup ne bi uticao na izbor atributa prije finalne evaluacije.

Standardizacija (Z-score normalizacija) je neophodna prije svega zbog algoritma k-NN, koji klasifikaciju vrši na osnovu Euklidskog rastojanja:

$$d(x, y) = \sqrt{\sum (x_i - y_i)^2}$$

Bez skaliranja, atributi velikog opsega (npr. U_s ~230–400 ili Temp ~13000–53000) bi potpuno dominirali nad atributima malog opsega (npr. Vib ~0.01–0.07), čime bi se prostor rastojanja netačno deformisao. Formula standardizacije:


$$x' = (x - \mu) / \sigma$$

4. Eksplorativna analiza podataka

Eksplorativna analiza sprovedena je prije treniranja modela kako bi se bolje razumjela struktura podataka, uočile eventualne anomalije i ispitale korelacije između atributa.


4.1 Korelacija atributa sa ciljnom promjenljivom

Analiza pokazuje da praktično svi atributi imaju izuzetno visoku korelaciju sa ciljnom promjenljivom ($|r| > 0.95$ za većinu atributa). Ovo je očekivano i fizički opravdano - gubitak jedne faze izaziva drastične, kvalitativno različite promjene u svim mjerenim veličinama motora (pad napona, skok struje, klizanje preko 1.0, kolaps brzine, skok THD-a), tako da se klase praktično ne preklapaju ni po jednom atributu.



Slika2: Atributi rangirani po apsolutnoj korelaciji sa klasom


4.2 Korelaciona matrica



Slika3: Korelaciona matrica svih atributa

Korelaciona matrica potvrđuje da su pojedini atributi međusobno izuzetno jako korelisani (npr. s, Brzina i Temp), što je očekivano jer su sve te veličine direktna posljedica istog fizičkog fenomena - gubitka sinhronizma motora tokom nestanka jedne faze. Ova informacija je kasnije iskorišćena prilikom interpretacije rezultata odabira atributa.


4.3 Distribucija atributa po klasama



Slika4: Boxplot prikaz svih atributa grupisanih po klasi

Boxplot prikazi jasno pokazuju da se opsezi vrijednosti za klasu 0 (zdrav rad) i klasu 1 (gubitak faze) ne preklapaju ni za jedan atribut, što direktno objašnjava zašto su modeli kasnije postigli izuzetno visoke metrike. Nisu uočeni outlieri koji bi ukazivali na greške u mjerenju ili simulaciji - svi ekstremi su fizički konzistentni sa očekivanim ponašanjem motora u kvaru.

4.4 Separacija klasa - primjer 2 atributa



Slika 5: Separacija klasa u prostoru struje statora i brzine rotora

Scatter dijagram struje statora (I_s) i brzine rotora (Brzina) vizuelno potvrđuje savršenu linearnu separabilnost klasa: zdrav rad karakteriše visoka brzina i niža struja, dok gubitak faze karakteriše kolaps brzine (blizu nule ili blago negativno usled oscilacija) uz drastično povišenu struju.

Na osnovu rezultata eksplorativne analize zaključeno je da podaci ne zahtevaju dodatnu obradu (uklanjanje outliera, transformaciju ili balansiranje), te da je dataset spreman za fazu treniranja modela.

5. Korišćeni modeli i izbor modela

U projektu su korišćena dva klasična algoritma za binarnu klasifikaciju:


- Logistička regresija (Logistic Regression) — linearni model koji kombinaciju ulaznih atributa propušta kroz sigmoidnu funkciju $f(x) = \sigma(wTx + b) = 1 / (1 + e^{-(wTx+b)})$, čiji izlaz predstavlja vjerovatnoću pripadnosti klasi kvara. Optimizacija parametara w i b vrši se minimizacijom funkcije unakrsne entropije (Binary Cross-Entropy Loss).
- k-najbližih susjeda (k-NN) — metoda zasnovana na rastojanju, koja novu tačku klasifikuje na osnovu glasanja k najbližih komšija u prostoru atributa, koristeći Euklidsko rastojanje kao mjeru sličnosti.

Oba modela su trenirana i evaluirana na istom trening/test skupu (80:20, stratifikovano), uz primjenu 5-fold unakrsne validacije (cross-validation) na trening skupu radi pouzdanije procjene performansi prije konačne evaluacije na test skupu.

6. Podešavanje hiperparametara

6.1 Logistička regresija - parametar C

Parametar C kontroliše jačinu regularizacije modela: manje vrijednosti C znače jaču regularizaciju i jednostavniji model, dok veće vrijednosti C dozvoljavaju modelu da se više prilagođava trening podacima. Testiran je opseg vrijednosti $C \in \{0.001, 0.01, 0.1, 1, 10, 100\}$ pomoću 5-fold unakrsne validacije na trening skupu.




Slika6: F1 score u zavisnosti od vrijednosti hiperparametra C

Hiperparametar	Najbolja vrijednost
C	0.001
Najbolji CV F1-score	1.0000

Zbog već izuzetno jasne separabilnosti klasa, F1-score je iznosio 1.0000 za sve testirane vrijednosti C , te je odabrana najmanja vrijednost ($C = 0.001$, najjača regularizacija) kao konačan izbor, jer daje najjednostavniji i najrobusniji model bez gubitka performansi.

6.2 k-NN - broj susjeda k

Testiran je opseg $k \in [1, 20]$ pomoću 5-fold unakrsne validacije na trening skupu, radi pronalaska optimalnog broja susjeda.



Slika7: F1 score u zavisnosti od hiperparametra k



Hiperparametar	Najbolja vrijednost
k	1
Metrika rastojanja	Euklidsko
Najbolji CV F1-score	1.0000

Svaka testirana vrijednost k (od 1 do 20) dala je identičan F1-score od 1.0000 na unakrsnoj validaciji, što dodatno potvrđuje da su klase u prostoru atributa potpuno odvojene. Odabran je k = 1 kao najjednostavnija konfiguracija.

7. Evaluacija finalnih modela


Nakon podešavanja hiperparametara, oba finalna modela evaluirana su na test skupu (280 uzoraka), koji nije učestvovao ni u treniranju ni u izboru hiperparametara.

Metrika	Logistička regresija	k-NN
Accuracy	1.0000	1.0000
Precision	1.0000	1.0000
Recall	1.0000	1.0000
F1-score	1.0000	1.0000
ROC-AUC	1.0000	1.0000



Slika8: Matrije konfuzije finalnih modela (test skup, 140+140 uzoraka)

Matrica konfuzije oba modela pokazuje da su svi uzorci tačno klasifikovani — 140 od 140 zdravih i 140 od 140 pokvarenih uzoraka, bez ijedne pogrešne predikcije (FP = 0, FN = 0).



Slika9: ROC krive finalnih modela

ROC-AUC vrijednost od 1.0000 za oba modela pokazuje savršenu separaciju klasa kroz sve moguće pragove odlučivanja.

7.1 Diskusija - zašto su metrike savršene

Savršene metrike (100% na svim pokazateljima) nisu posljedica greške u metodologiji niti curenja podataka (data leakage), što je dodatno potvrđeno time što je standardizacija fitovana isključivo na trening skupu, a podjela na trening i test skup izvršena pre bilo kakve obrade. Razlog leži u fizičkoj prirodi simuliranog kvara: gubitak jedne faze predstavlja toliko drastičnu promjenu radnog režima motora (pad napona sa $\sim 400V$ na $\sim 230V$, skok struje, klizanje koje prelazi vrijednost 1.0, kolaps brzine rotora) da između dvije klase praktično ne postoji preklapanje ni u jednom atributu, što je potvrđeno i analizom korelacija, gdje su pojedini atributi imali korelaciju sa klasom blisku -1 ili 1 .

U realnim, šumovitim industrijskim mjerenjima ovakva savršena separacija klasa ne bi bila tipična, ali za simulacione podatke generisane iz matematičkog modela motora, ovaj rezultat potvrđuje da su izabrane fizičke veličine izuzetno pogodne za detekciju ovog konkretnog tipa kvara.

8. Odabir najznačajnijih atributa

Radi ispitivanja da li je za uspješnu klasifikaciju zaista neophodno svih 8 atributa, primjenjene su dvije metode za odabir najznačajnijih atributa, isključivo nad trening skupom:

- SelectKBest (F-test) — statistički test koji mjeri koliko svaki atribut individualno korelira sa ciljnom klasom.
- RFE (Recursive Feature Elimination) — metoda koja iterativno uklanja najmanje važne attribute na osnovu težina modela logističke regresije, sve dok ne ostane zadati broj atributa.

Obe metode su, nezavisno jedna od druge, izdvojile identičan skup od 4 najznačajnija atributa:

- U_s — efektivni napon statora
- s — klizanje motora
- Brzina — mehanička brzina rotora
- Temp — temperatura motora

Poklapanje rezultata dvije nezavisne metode dodatno potvrđuje pouzdanost odabira. Atributi P_f , I_s , THD i Vib su rangirani kao manje značajni, što je u skladu sa zapažanjem iz korelacione matrice da su U_s , s , Brzina i Temp međusobno najjače korelisani sa klasom.

8.1 Poređenje rezultata – Svi VS najznačajniji atributi

Skup atributa	Broj atributa	Accuracy	Precision	Recall	F1-score
Svi atributi	8	1.0000	1.0000	1.0000	1.0000
Top 4 atributa (SelectKBest / RFE)	4	1.0000	1.0000	1.0000	1.0000

Model treniran samo sa 4 najznačajnija atributa postigao je identične rezultate kao model sa svih 8 atributa. Ovo pokazuje da se, uz minimalan gubitak informacija, kompleksnost modela može značajno smanjiti — što je posebno korisno u kontekstu realne (npr. HIL) primjene, gdje mjerenje manjeg broja signala (napon, klizanje, brzina, temperatura) zahtjeva manje senzora i nižu cijenu implementacije u odnosu na mjerenje svih osam veličina.

9. Deployment modela

Za praktičnu upotrebu razvijenih modela, izvršen je export oba trenirana modela (logistička regresija i k-NN) zajedno sa obučenim StandardScaler-om u jedan .pkl fajl (motor_fault_detection.pkl), koji sadrži sve neophodne komponente za primjenu modela na nove podatke.

Jednostavno korišćenje modela omogućeno je kroz komandno-linijski (CLI) korisnički interfejs koji omogućava:

- izbor jednog od dva trenirana modela (logistička regresija ili k-NN)
- ručni unos vrijednosti svih osam senzorskih veličina motora
- automatsko skaliranje unijetih vrednosti prema parametrima naučenim na trening skupu
- prikaz predviđene klase (zdrav rad / kvar) i procjenjene vjerovatnoće kvara u procentima
- mogućnost višestrukih uzastopnih predikcija u istoj sesiji

Funkcija predikcije je realizovana tako da prima sirove (neskalirane) vrijednosti fizičkih veličina motora, primjenjuje isti scaler korišćen tokom treniranja i vraća klasu i procjenjenu vjerovatnoću pripadnosti klasi kvara. Tom prilikom testirana su dva tipična scenarija - unos vrijednosti karakterističnih za zdrav rad motora i unos vrijednosti karakterističnih za gubitak faze - pri čemu je model u oba slučaja vratio očekivanu, fizički ispravnu predikciju.

10. Zaključak

U projektu je realizovan kompletan tok rada za binarnu klasifikaciju režima rada asinhronog motora na osnovu fizičkih veličina dobijenih iz Simulink simulacije. Sprovedeni su preprocesiranje podataka, eksplorativna analiza, treniranje i poređenje dva modela (logistička regresija i k-NN) obrađena u okviru predmeta, podešavanje hiperparametara putem unakrsne validacije, finalna evaluacija na test skupu, odabir najznačajnijih atributa pomoću dvije nezavisne metode i jednostavan deployment modela kroz CLI interfejs.

Oba finalna modela — logistička regresija ($C = 0.001$) i k-NN ($k = 1$) - ostvarila su savršene rezultate na test skupu (Accuracy = Precision = Recall = F1-score = ROC-AUC = 1.0000), što je posljedica izrazito jasne fizičke separacije između zdravog rada i gubitka faze u simulacionim podacima, a ne metodološke greške, što je potvrđeno dosljednom primjenom pravila za sprečavanje data leakage-a kroz cijeli projekat.

Analiza atributa pokazala je da se identične performanse mogu postići i sa svega 4 od 8 raspoloživih atributa (U_s , s , Brzina, Temp), što ukazuje na mogućnost pojednostavljenja sistema za detekciju u praksi, kroz smanjenje broja potrebnih senzora.